Prédiction NPS pour un opérateur télécom

Seuls 15% des clients de cet opérateur télécom répondent à l'enquête NPS. L'équipe rétention a besoin d'une catégorie prédite Detractor, Passive ou Promoter pour les 85% restants, afin de prioriser les actions avant résiliation. Ce cadrage guide les choix méthodologiques du projet : le modèle doit généraliser à des clients qui ne ressemblent pas aux répondants, pas seulement bien prédire ces derniers.

1. Construction de la variable cible

Le dataset IBM Telco (v11.1.3+, 7 043 clients) fournit un score de Satisfaction de 1 à 5, pas un score NPS de 0 à 10. Nous avons utilisé le mapping de base du brief 5 → Promoter, 4 → Passive, 1–3 → Detractor puisqu'aucun seuil NPS littéral ne s'applique à une échelle 1–5.

Distribution des classes obtenue : **58.3% Detractor, 25.4% Passive, 16.3% Promoter.** Ce déséquilibre est réel, pas un artefact de modélisation, et façonne chaque décision d'évaluation qui suit (Section 5).

Fuite de données (leakage). Le dataset contient aussi `Churn Score`, `Churn Value`, `Churn Label`, `Churn Reason`, `Churn Category`, `Customer Status`, et `CLTV` des champs liés au résultat final, inconnus pour un client qui n'a pas encore résilié ainsi que `Satisfaction Score` lui-même, qui est le label. Ces huit colonnes sont bannies en permanence du jeu de features vérifié à chaque construction de features.

Sensibilité du label. Une variante bruitée du label (10.5% des lignes réassignées à une classe adjacente, jamais un saut de deux crans) teste l'impact du choix de construction du label. Entraîner dessus fait chuter le QWK d'environ 23% en relatif (0.269 → 0.207) un coût réel. Si la collecte réelle du label est aussi bruitée en production, c'est la perte de performance à anticiper, et cela tempère la confiance dans le classement précis des features (Section 6).

2. Stratégie de validation

Deux splits ont été construits, délibérément inégaux en statut :

- **Split réaliste (principal).** 15% des clients (1 056) sont échantillonnés comme "répondants" via un modèle de propension favorisant faible satisfaction et forte ancienneté, cohérent avec l'intuition que les clients mécontents et fidèles répondent plus aux enquêtes. Les 85% restants (5 987) forment la population "silencieuse", utilisée uniquement pour l'évaluation. Cet échantillon n'est pas représentatif : 80.3% Detractor contre 58.3% globalement, satisfaction moyenne 2.60 contre 3.24. C'est précisément le but recherché : reproduire un vrai jeu d'entraînement collecté de cette façon.
- **Split aléatoire (comparaison uniquement).** Un split stratifié 70/30 classique, utilisé seulement pour vérifier "ce modèle apprend-il quelque chose sur ces données", jamais comme classement de référence.

Les deux splits ne désignent pas le même modèle gagnant (Section 5) c'est la conclusion la plus lourde de conséquences de toute la phase de modélisation. Un modèle choisi sur le seul split aléatoire aurait été le mauvais choix en production.

3. Feature engineering

35 features (38 à l'origine, trois retirées pour raisons d'équité Section 7), réparties en sept groupes métier : ancienneté, contrat & facturation, charges (dont un ratio charges par service), services (bundles streaming/sécurité), engagement (parrainages, offres), composition du foyer, et géographie (écartée voir Section 7).

Deux champs Offer et Internet Type sont manquants de façon **structurelle** (pas d'offre souscrite, pas de service internet) plutôt qu'aléatoirement manquants, et sont remplis par une catégorie "aucun" explicite plutôt qu'imputés statistiquement, car imputer une moyenne numérique sur "client sans internet" dénaturerait la donnée.

4. Modélisation et évaluation

Pourquoi ordinal, pas une classification classique. Les catégories NPS sont ordonnées (Detractor < Passive < Promoter) : confondre un Detractor avec un Promoter est pire qu'avec un Passive, une distinction qu'une

classification multi-classe classique ignore. Quatre approches comparées: baseline naïve, régression logistique multinomiale, modèle ordinal (`mord.LogisticAT`), et gradient boosting (LightGBM), plus une variante régression-avec-seuils couvrant les trois cadrages que le brief demande de peser.

Métriques. L'accuracy est exclue comme critère de décision (elle récompense un modèle qui prédit "Detractor" pour tout le monde, vu le déséquilibre). Nous utilisons le quadratic weighted kappa (QWK, la métrique standard pour l'accord ordinal), le macro-F1, la balanced accuracy, le rappel par classe, le lift cumulatif sur Detractor, et des courbes de calibration. Le QWK reste la métrique principale, conçue précisément pour ce type de problème.

Résultats (split réaliste, évalués sur les 5 987 clients silencieux, intervalles de confiance bootstrap à 95% entre crochets) :

Modèle	QWK	Rappel Detractor	Ce qui s'est passé
Baseline majoritaire	0.000	1.000	Prédit tout le monde en Detractor le plancher, pas une vraie option
LightGBM, paramètres par défaut	0.089 [0.071, 0.108]	0.909	S'effondre vers "toujours Detractor" sur le petit échantillon d'entraînement biaisé
LightGBM, ajusté (2 rounds)	0.224 [0.200, 0.249]		Une forte régularisation récupère plus de la moitié de l'écart, pas tout
Régression logistique	0.225 [0.198, 0.250]	0.619	Compétitive, mais non ordinale
Ordinal Logistic (mord.LogisticAT) déployé	**0.273**	0.518	Le seul modèle qui ne se dégrade pas entre split aléatoire et split réaliste

Le QWK du modèle déployé reflète un changement de features fait pour des raisons d'équité (Section 7), pas une optimisation de performance. Son prédécesseur (mêmes features de foyer en plus) obtenait 0.269, IC à 95% [0.244, 0.293] ; 0.273 reste dans cet intervalle, confirmant que le correctif d'équité n'a rien coûté.

Constat principal: LightGBM semble bon sur le split aléatoire (QWK 0.270) mais s'effondre sur le split réaliste (QWK 0.089) sa flexibilité lui fait sur-apprendre le petit échantillon biaisé de 1 056 répondants, puis prédire "Detractor" pour presque tout le monde face à la population réelle, bien plus équilibrée. Le modèle ordinal, moins flexible, n'a pas ce défaut et s'améliore même légèrement sur le split réaliste. Chaque comparaison a été vérifiée par intervalle de confiance bootstrap : l'avantage du modèle ordinal résiste à cette vérification.

5. Drivers de détraction

L'analyse SHAP trouve que les trois mêmes drivers dominent sur chaque segment client testé (nouveaux vs. anciens clients, contrat mensuel vs. annuel, fibre vs. DSL) : **Monthly Charges, l'accès internet en fibre, et l'absence d'Online Security.** Seul leur classement relatif change selon le segment.

Driver	Actionnable ?	Levier suggéré
Monthly Charges	Oui	Tarification de rétention ciblée pour les clients à charge élevée relativement à leur segment
Internet en fibre	Partiellement	L'infrastructure en soi n'est pas modifiable, mais se combine à un levier qualité de service/prix (les données de motif de résiliation pointent vers des plaintes liées à la concurrence)

Driver	Actionnable ?	Levier suggéré
Absence d'Online Security	Oui	Bundling proactif plutôt qu'attendre une souscription spontanée
Contrat mensuel	Oui	Inciter à la montée vers un contrat annuel
Ancienneté	Non, directement	On ne peut pas changer depuis quand quelqu'un est client on peut changer l'onboarding des nouveaux clients

Aucun attribut démographique (genre, senior citizen, partner, dependents) n'apparaît dans le top 5 des drivers d'aucun segment un signal encourageant mais *préliminaire*, supplanté ensuite par l'audit d'équité direct de la Section 7, qui est le test qui compte vraiment pour cette question.

6. Équité et biais

L'exemple du brief lui-même est un modèle qui "détecte 80% des jeunes détracteurs mais seulement 50% des détracteurs seniors.

Ce que nous avons trouvé, et ce que nous en avons fait :

- **Senior Citizen: aucun écart** (rappel ≈52% dans les deux cas l'exemple d'alerte du brief lui-même ne se produit pas dans ce modèle).
- **Gender: un écart réel et modéré** 54% de rappel pour les clients hommes contre 49% pour les clientes femmes, un écart confirmé par son intervalle de confiance. Non traité à ce stade (voir Section 9).
- **Dependents: un écart réel et important** 55% de rappel pour les clients sans personne à charge contre 36% pour ceux qui en ont, soit 19 points, bien au-delà du bruit d'échantillonnage. Inacceptable selon le standard du brief. Retirer seul le champ `Dependents` ne changeait presque rien (une feature dérivée réencodait la même information sous un autre nom) ; retirer les trois champs liés ensemble a réduit l'écart de 19 à 12 points, sans coût sur le QWK. Ce correctif est dans le modèle déployé. L'écart résiduel de 12 points reste un point à escalader vers Customer Experience ou Legal avant toute allocation de budget de rétention nous ne l'avons pas entièrement expliqué.
- **La géographie** a été testée comme feature optionnelle et n'apporte aucun gain de performance mesurable tout en introduisant exactement le type de risque de proxy dont le brief met en garde. Elle est exclue du modèle déployé pas un arbitrage, puisqu'il n'y avait rien à arbitrer. Le code postal et la ville bruts ne sont jamais utilisés comme features, dans aucune configuration.

7. Verbatims synthétiques

Conformément à la piste bonus du brief, une dernière note d'interaction synthétique a été générée par client (7 043 au total, en français, via Google Gemini, par lots) ancrée dans l'ancienneté, le contrat et les services de chaque client, avec un ton correspondant à la vraie catégorie NPS pour ~82% des clients et délibérément discordant pour le reste, afin d'éviter une corrélation texte-label parfaitement propre.

Nous avons ensuite encodé ces notes (embeddings de phrases multilingues, réduits à 20 composantes) et les avons ajoutées au modèle tabulaire. **Résultat affiché : le QWK bondit de 0.273 à 0.875.**

Les verbatims ont été rédigés par un LLM informé du niveau de satisfaction réel du client avant d'écrire un modèle qui lit le ton de ce texte est proche de relire le label dans sa propre reformulation. Pour quantifier l'effet, nous avons scindé le jeu de test entre les ~82% de notes dont le ton correspond au vrai label et les ~18% délibérément discordantes.

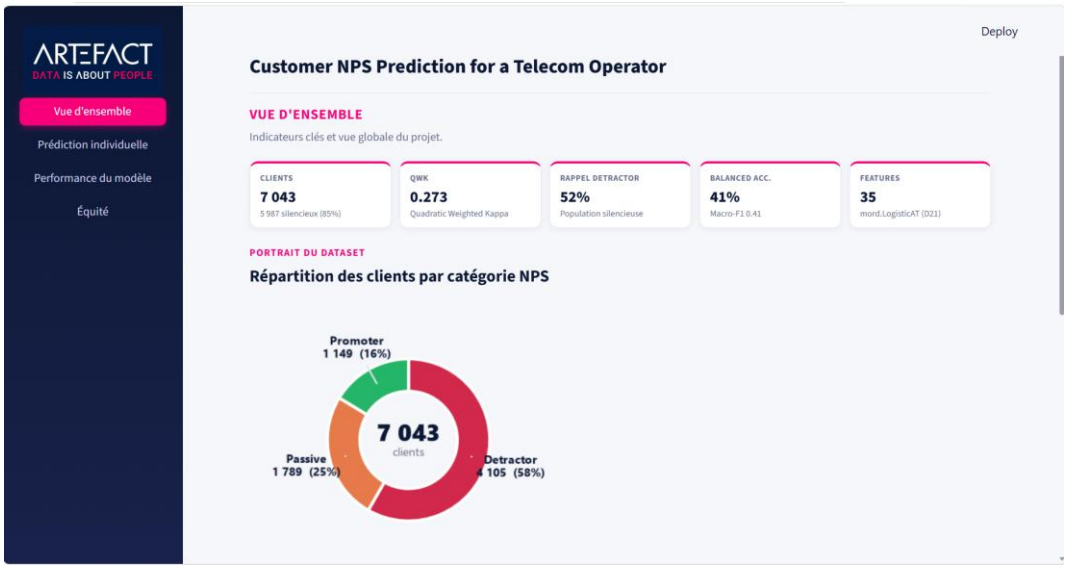
8. Présentation du Dashboard

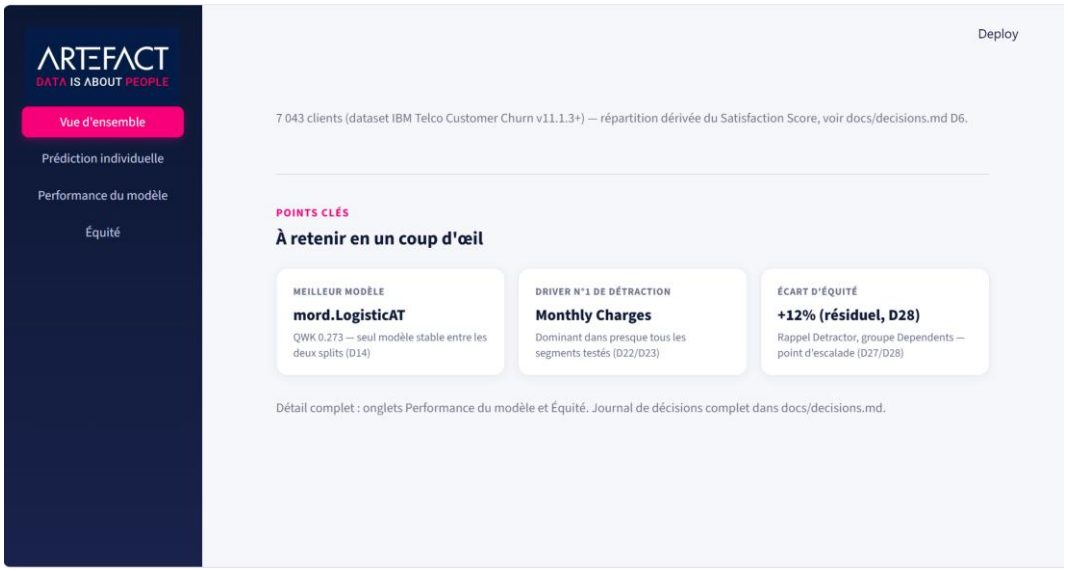
Le pipeline déployé persiste le modèle entraîné sous forme d'artefact joblib afin qu'il puisse être réutilisé pour l'inférence sans jamais ré-entraîner le dashboard ci-dessous se contente de charger cet artefact.

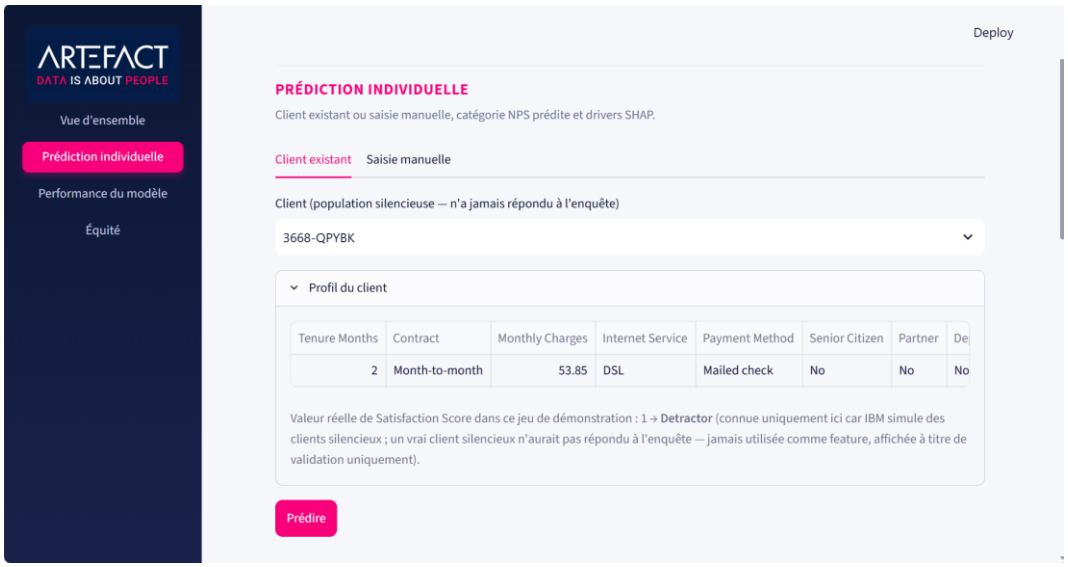
Un dashboard Streamlit organise le produit en quatre pages.

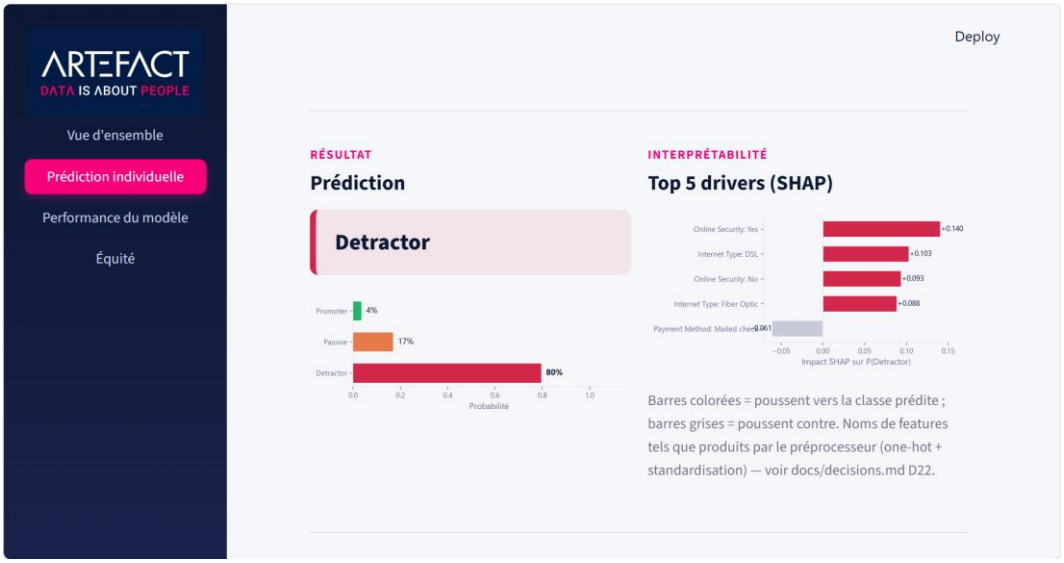
- **Vue d'ensemble** donne un instantané niveau direction: indicateurs clés (QWK, rappel Detractor, nombre de features), répartition des catégories NPS, et une bande de points clés, calculés en direct contre le modèle et les fichiers réellement présents sur le disque.
- **Prédiction individuelle** est l'outil central: un conseiller choisit un client existant de la population silencieuse ou saisit un profil manuel, et voit la catégorie prédite, les probabilités des trois classes, et les cinq principaux drivers SHAP. Les champs dépendants sont masqués plutôt que validés après coup.
- **Performance du modèle** et **Équité** reprennent les conclusions des Sections 5 et 7 directement dans l'outil, y compris l'écart Dependents non résolu. Un fichier modèle manquant est géré par un message clair, pas un plantage. Un panneau bonus pour coller un verbatim client est visible mais indique honnêtement qu'il n'est pas branché à une prédiction live le modèle enrichi de texte existe (Section 8) mais a été jugé trop peu fiable.

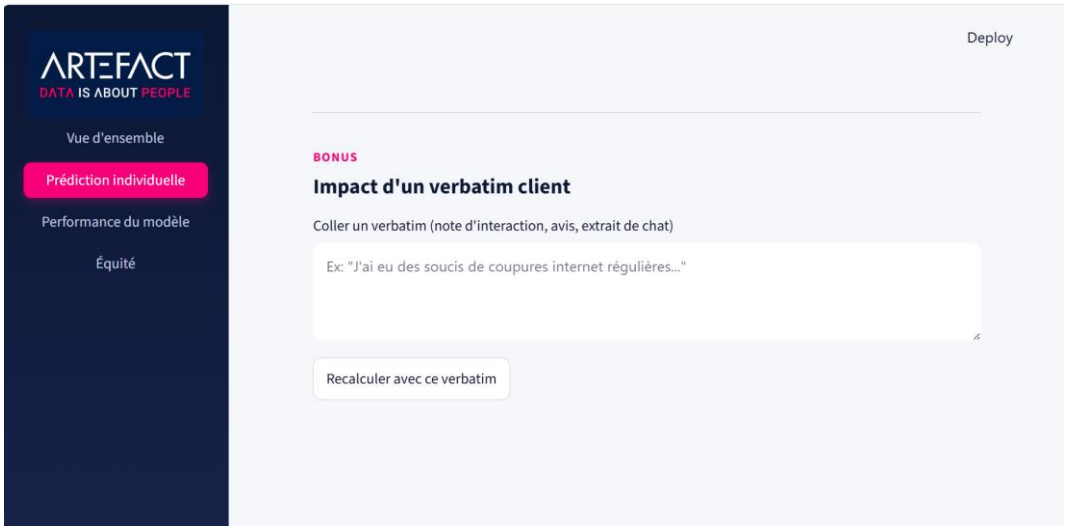
Captures d'écran. Les huit captures ci-dessous parcourent les quatre pages dans l'ordre. Chaque légende explique ce que montre cette partie de l'interface, pas les chiffres qui y apparaissent ceux-ci sont déjà commentés dans les sections correspondantes ci-dessus.

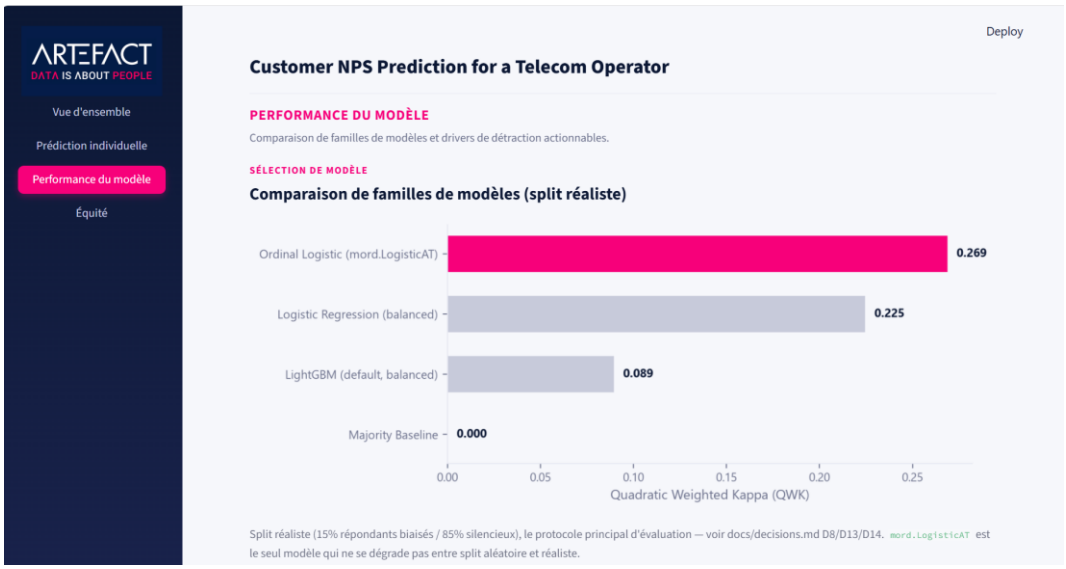


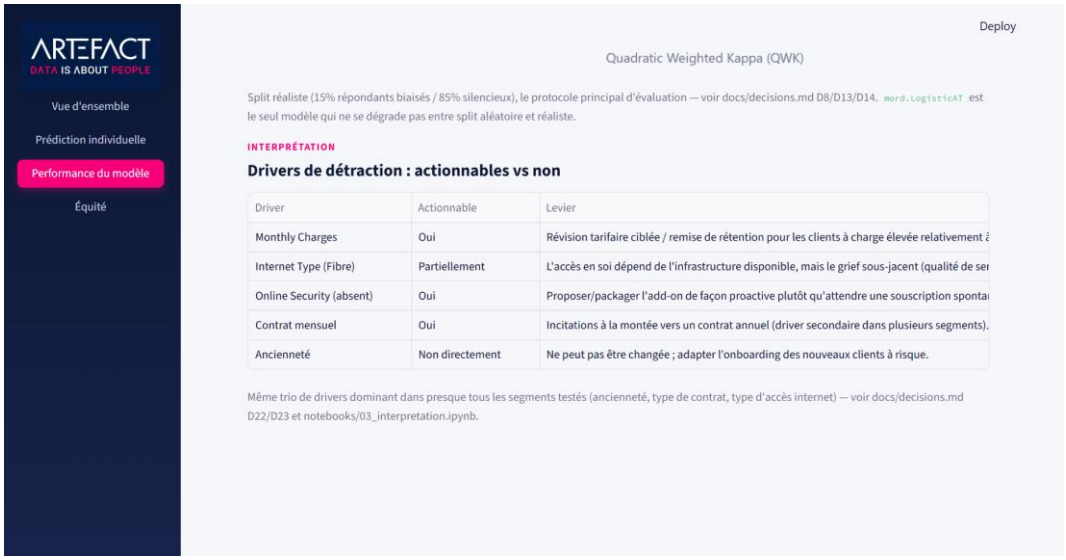


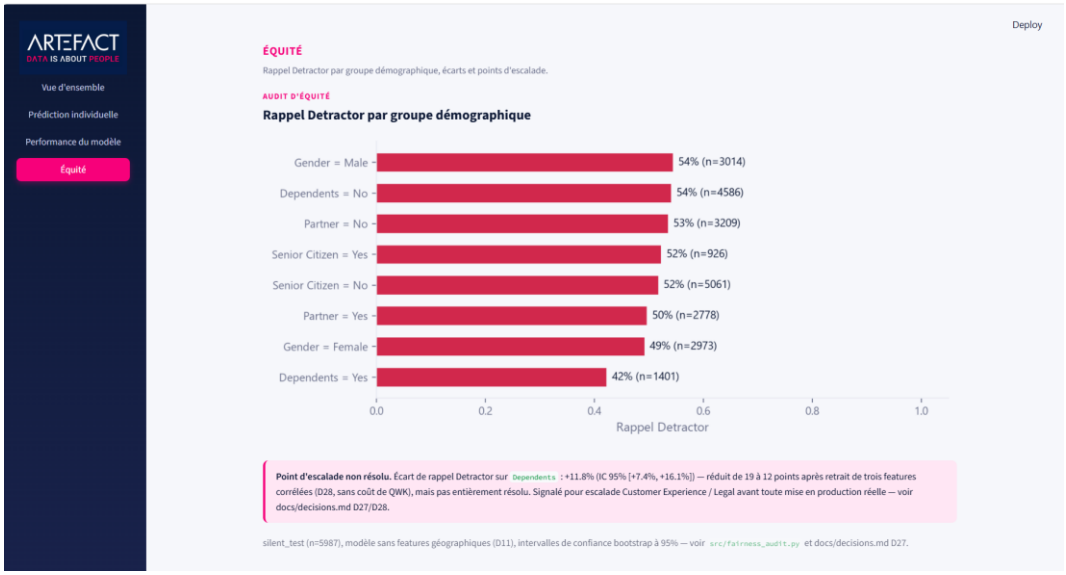

ARTEFACT
DATA IS ABOUT PEOPLE
Vue d'ensemble
Prédiction individuelle
Performance du modèle
Équité
Deploy
PRÉDICTION INDIVIDUELLE
Client existant ou saisie manuelle, catégorie NPS prédite et drivers SHAP.
Client existant
Saisie manuelle
Client (population silencieuse — n'a jamais répondu à l'enquête)
3668-QPYBK
Profil du client
Tenure Months
Contract
Monthly Charges
Internet Service
Payment Method
Senior Citizen
Partner
2
Month-to-month
53.85
DSL
Mailed check
No
No
Valeur réelle de Satisfaction Score dans ce jeu de démonstration : 1 → Detractor (connue uniquement ici car IBM simule des clients silencieux ; un vrai client silencieux n'aurait pas répondu à l'enquête — jamais utilisée comme feature, affichée à titre de validation uniquement).
Prédire


ARTEFACT
DATA IS ABOUT PEOPLE
Vue d'ensemble
Prédiction individuelle
Performance du modèle
Équité
Deploy
RÉSULTAT
Prédiction
Detractor
Promoter
Passive
Detractor
4%
17%
80%
Probabilité
INTERPRÉTABILITÉ
Top 5 drivers (SHAP)
Online Security: Yes
Internet Type: DSL
Online Security: No
Internet Type: Fiber Optic
Payment Method: Mailed check
+0.140
+0.103
+0.093
+0.088
-0.061
Impact SHAP sur P(Detractor)
Barres colorées = poussent vers la classe prédite ; barres grises = poussent contre. Noms de features tels que produits par le préprocesseur (one-hot + standardisation) — voir docs/decisions.md D22.


ARTEFACT
DATA IS ABOUT PEOPLE
Vue d'ensemble
Prédiction individuelle
Performance du modèle
Équité
Deploy
BONUS
Impact d'un verbatim client
Coller un verbatim (note d'interaction, avis, extrait de chat)
Ex: "J'ai eu des soucis de coupures internet régulières..."
Recalculer avec ce verbatim







9. Limites

- **Les écarts Gender et le résiduel Dependents (Section 7) ne sont pas entièrement résolus.** Ils sont documentés et signalés pour escalade, pas corrigés. Décider de les accepter, d'investiguer davantage, ou d'exclure aussi Gender est une décision que ce projet met en lumière mais ne tranche pas unilatéralement

cela échange une précision mesurable contre un jugement de valeur sur la disparité acceptable, qui relève du métier, pas d'être enterré dans un script de modélisation.

- **Un seul tirage de l'échantillon de répondants a été testé.** Le tirage des 15% de répondants du split réaliste est fixé pour la reproductibilité. Les intervalles de confiance bootstrap capturent le bruit d'échantillonnage du jeu de test, pas "à quel point le modèle serait différent sous un autre tirage de répondants» cela nécessiterait de répéter tout le pipeline sous plusieurs graines aléatoires, non fait ici compte tenu du cadre de deux semaines.
- Le QWK de 0.875 du modèle enrichi de texte n'est pas une estimation fiable de l'apport d'un vrai texte client (Section 8). Nous avons diagnostiqué pourquoi et quantifié partiellement l'effet, mais ne pouvons pas séparer entièrement un signal texte authentique d'une reformulation de faits déjà connus. C'est une limite des verbatims synthétiques, pas un raccourci de modélisation à corriger.
- **TabPFN n'a pas été évalué** (Section 5) un vrai manque dans la piste bonus, pas caché.